


Belgeiz

Yapay Zeka Tabanlı Belge Analiz ve Soru Cevap Sistemi

Murat MAVZER — Eylül 2026



Ürün Özeti



Belgeiz, kullanıcıların **PDF ve görsel belgeleri** yükleyip bu içerikler hakkında doğal dilde soru sormasını sağlayan işlevsel bir MVP'dir. Sistem dijital metni doğrudan çıkarır, taranmış sayfalarda Türkçe ve İngilizce OCR çalıştırır, ilgili kanıt seçer ve yanıt **dosya ile sayfa bilgisiyle** birlikte sunar.

Yanıt Motoru

OpenAI API veya bilgisayarda ücretsiz çalışan Ollama modelleri

Kalite Durumu

34 otomatik test, %82 kod kapsamı ve bağımlılık kontrolü

Kullanıcı Deęeri



Tek Arayüz

Belge yükleme, okuma, soru sorma ve kaynak inceleme tek ekranda



Esnek Model

API bütçesi olanlar için bulut, maliyetsiz kullanım için yerel model seçimi



Güvenli Ret

Belgede olmayan bilgide standart ret; belgede bulunan iki veya daha fazla veriden kontrollü türetme



Kolay Kurulum

Windows'ta çift tıklamayla kurulum ve başlatma; Türkçe, sade ve modern kullanım



Temel tasarım kararı: Metin çıkarımı, parçalama ve arama yerelde tutulur. Üretken model yalnız seçilen kanıtla çalışır; model çıktısı kullanıcıya gösterilmeden önce uygulama katmanında yeniden doğrulanır.



Sistem Mimarisi

Belgelz iki ana veri yolundan oluşur. **Belge işleme yolu** yüklenen dosyayı güvenli ve sayfa kökeni korunmuş bir indekse dönüştürür. **Soru cevap yolu** bu indeksten kanıt seçer, seçilen sağlayıcıya gönderir ve sonucu kaynak kimlikleriyle doğrular.



Bileşen Sorumlulukları

app.py	Türkçe Streamlit arayüzü, oturum durumu, ilerleme ve belge yönetimi
extractors.py	Biçim kontrolleri, PyMuPDF metni, koşullu EasyOCR ve sayfa ilerlemesi
retrieval.py	BM25, terim kapsama ve yazım ya da çekim toleranslı kanıt sıralama
qa.py	Tam bağlam veya arama seçimi, sağlayıcı istemcileri ve çıktı doğrulama
service.py	Belge ekleme, çıkarma, indeks yenileme ve sağlayıcı orkestrasyonu

Teknoloji Yığını

MVP, ek servis bağımlılığını ve kurulum sürtünmesini düşük tutan bir Python mimarisi üzerine kurulmuştur. Her araç belirli bir sorumluluğu üstlenir; kanıt kontrolü bir çerçeve içine gizlenmez.

Katman	Teknoloji	Seçim Nedeni
Arayüz	Streamlit	Tek Python sürecinde hızlı MVP, oturum durumu ve özel Türkçe arayüz
PDF	PyMuPDF	Dijital PDF metnini hızlı ve sayfa bilgisi korunarak çıkarma
Görsel İşleme	Pillow	EXIF yönü, gri ton, kontrast ve boyut küçültme
OCR	EasyOCR ve PyTorch	Türkçe ve İngilizceyi ayrı native dil paketi olmadan okuma
Arama	BM25 ve difflib	Embedding API'si olmadan yerel, denetlenebilir ve hafif kanıt seçimi
Bulut Modeli	OpenAI Responses API	JSON şemalı çıktı ve kaynaklı yanıt sözleşmesi
Yerel Model	Ollama ve Qwen3	API anahtarsız, çevrimdışı ve farklı donanımlara uygun model boyutları
Test	pytest ve coverage	Birim, entegrasyon, arayüz ve Windows başlatıcı regresyonları
Dağıtım	CMD PowerShell ve Docker	Windows'ta çift tıklama ve taşınabilir çalışma seçenekleri

Alternatifler ve Yerel Modeller

Değerlendirilen Alternatifler

Tesseract: Güçlü bir seçenektir; ayrı binary ve Türkçe dil paketi kurulumu teslimatı zorlaştırdı.

FAISS / Chroma: Semantik aramayı güçlendirebilir; ek indeks, model ve eşik kalibrasyonu gerektirir.

PaddleOCR / RapidOCR: Hız açısından değerlendirildi; Windows paket ve model matrisi MVP riski oluşturdu.

LangChain / LlamaIndex: Geniş entegrasyon sunar; küçük bir MVP'de kritik kaynak doğrulama adımlarını görünmez hale getirebilir.

Yerel Model Seçenekleri

Kurulum menüsü Qwen3 seçeneklerini ayrı ayrı veya birlikte indirir.

Qwen3 1.7B

Düşük bellek için

Qwen3 4B Instruct

Hız ve kalite dengesi için

Qwen3 8B

Daha güçlü donanımda daha iyi analiz için

Sistem Özellikleri ve Kanıt Güvenliği



Belge İşleme

Çoklu PDF, JPG, JPEG ve PNG yükleme; dosya başına 20 MB, PDF için 100 sayfa ve görsel için 40 megapiksel sınırı. Metin PDF'lerinde doğrudan PyMuPDF; yalnız kısa ya da okunamayan sayfalarda OCR geri dönüşü. Türkçe ve İngilizce OCR, görüntü ön işleme, süreç çapında model önbelleği ve sayfa bazlı ilerleme.



Soru Cevap

Küçük belgelerde tüm bağlamı inceleme; büyük koleksiyonlarda hibrit BM25 ve komşu parça genişletme. Ayrı kaynaklardaki değerlerden toplam, fark, oran, yüzde, ortalama, tarih sırası ve kısa karşılaştırma türetme. Yanıtta dosya, sayfa ve ham kanıt gösterme; ilgisiz soruda model çağrısından önce güvenli ret.



Kullanılabilirlik

OpenAI ile yerel Ollama arasında arayüzden geçiş ve Ollama model sağlık kontrolü. Yanlış belgeyi çıkarma, indeksi yeniden kurma ve geçersiz sohbet geçmişini temizleme. Türkçe arayüz, özel buton durumları, gizlenmiş Streamlit reklam öğeleri ve telemetri kapatma. Belgelz.cmd ile otomatik paket ve OCR kurulumu; YerelModelKur.cmd ile seçimli model kurulumu.



Kanıt Güvenliği: Model yalnız SOURCE bloklarını kullanır ve belge içindeki talimatları güvenilmeyen veri sayar. Çıktıda grounded, answer ve citation_ids alanları zorunludur. Kaynak kimliği aktif kanıt listesinde değilse, atıf boşsa veya gerekli ara veri eksikse uygulama cevabı standart ret mesajına dönüştürür.

Örnek Demo Gösterimi

Örnek Demo Senaryosu

Birinci kaynak bir sınav sonuç belgesini, ikinci kaynak hastane tetkik raporunu içermektedir. Bu belgeler içerisinde akıl yürütme, aritmetik işlemler gibi işlemler yürütebilmektedir. Ayrıca belgede bulunmayan bir hedef sorulduğunda "Bu bilgi yüklenen belgelerde bulunamadı." yanıtını gösterir.

Demo Gösterimi

- Arayüz tanıtımı
- PDF ve taranmış belge tarama süreçleri
- OpenAI API vs yerel Ollama model modlarının kullanımları
- Alınan cevaplarda referans gösterimleri

Belgelz'in temel farkı, yalnızca cevap üretmesi değil, cevabın hangi dosya ve sayfadan geldiğini doğrulaması ve gerektiğinde birden fazla belge verisini kontrollü biçimde birleştirmesidir. Aynı mimari OpenAI ile yüksek kaliteyi, Ollama ile API maliyeti olmadan yerel çalışmayı destekler.